

STK1110 - Statistiske metoder og dataanalyse:

Obligatorisk øving 1 av 2

Vegard Nyquist Borgeraas

Høst 2026

Oppgave 1

(a)

Ved å sette de empiriske momentene lik de teoretiske, får vi følgende likningssystem:

$$M_1 := \frac{1}{n} \sum_{i=1}^n x_i \stackrel{!}{=} \frac{\alpha}{\gamma}$$
$$M_2 := \frac{1}{n} \sum_{i=1}^n x_i^2 \stackrel{!}{=} \text{Var}(X) + E[X]^2 = \frac{\alpha}{\gamma^2} + \left(\frac{\alpha}{\gamma}\right)^2$$

Løser vi dette systemet for de to ukjente parametrene, får vi momentestimatorene:

$$\hat{\gamma} = \frac{M_1}{M_2 - M_1^2}$$
$$\hat{\alpha} = \frac{M_1^2}{M_2 - M_1^2}$$

Resultatene passer godt med boken. Siden vi har at;

$$\hat{\gamma} = \frac{M_1}{M_2 - M_1^2} = \frac{1}{\hat{\beta}_{\text{bok}}}$$

Som passer bra med at $\beta = 1/\gamma$.

Kode for å beregne empiriske momentene basert på forsikringsdataene.

```
data <- scan("forsikringskrav.txt")

M1 <- mean(data)
M2 <- mean(data^2)

alpha <- M1^2 / (M2 - M1^2)
gamma <- M1 / (M2 - M1^2)
```

Den git at $\hat{\gamma}_{\text{mom}} = 0.696649$ og $\hat{\alpha}_{\text{mom}} = 0.02886053$

(b)

Log-likelihood funksjonen, $l(\alpha, \gamma)$ finner vi ved å ta den naturlige logaritmen av likelihood funksjonen. Ved å bruke vanlige logaritmereglene gjøres produktet om til en sum:

$$\begin{aligned} l(\alpha, \gamma) &= \sum_{i=1}^n \ln(f(x_i|\alpha, \gamma)) \\ &= \sum_{i=1}^n \ln\left(\frac{\gamma^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\gamma x_i}\right) \\ &= \sum_{i=1}^n (\alpha \ln(\gamma) - \ln(\Gamma(\alpha)) + (\alpha - 1) \ln(x_i) - \gamma x_i) \\ &= n\alpha \ln(\gamma) - n \ln(\Gamma(\alpha)) + (\alpha - 1) \sum_{i=1}^n \ln(x_i) - \gamma \sum_{i=1}^n x_i \end{aligned}$$

Implementasjon:

```
l <- function(x, alpha, gamma) {  
  n <- length(x)  
  n * alpha * log(gamma) - n * lgamma(alpha) +  
  (alpha - 1) * sum(log(x)) - gamma * sum(x)  
}
```

Den gir at $l(\hat{\alpha}_{\text{mom}}, \hat{\gamma}_{\text{mom}}) = -27264.51$.

(c)

For å finne maksimum likelihood-estimatoren for γ tar vi den partiellderiverte av $l(\alpha, \gamma)$ med hensyn på γ , og sette uttrykket lik null.

$$\begin{aligned} \frac{\partial l}{\partial \gamma} &= \frac{\partial}{\partial \gamma} \left(n\alpha \ln(\gamma) - n \ln(\Gamma(\alpha)) + (\alpha - 1) \sum_{i=1}^n \ln(x_i) - \gamma \sum_{i=1}^n x_i \right) \\ &= \frac{n\alpha}{\gamma} - \sum_{i=1}^n x_i \end{aligned}$$

For å finne maksimumspunktet, setter vi den deriverte lik null:

$$\frac{n\alpha}{\gamma} - \sum_{i=1}^n x_i = 0$$

Løser vi denne ligningen for γ , får vi maksimum likelihood-estimatoren:

$$\hat{\gamma}_{\text{ML}} = \frac{n\alpha}{\sum_{i=1}^n x_i} = \frac{\alpha}{\frac{1}{n} \sum_{i=1}^n x_i} = \frac{\alpha}{\bar{x}}$$

Fra (a) har vi at:

$$\bar{x} = \frac{\alpha}{\gamma} \implies \gamma = \frac{\alpha}{\bar{x}}$$

Dermed sammsvarar de.

(d)

Implementasjon av numerisk optimering:

```
negloglikgamma <- function(logalpha,x=x) {  
  n <- length(x)  
  alpha <- exp(logalpha)  
  gamma <- alpha/mean(x)  
  logL <- n*alpha*log(gamma)-n*lgamma(alpha)+  
  (alpha-1)*sum(log(x))-gamma*sum(x)  
  -logL  
}  
  
fit.ml <- optim(log(alpha), negloglikgamma, x=x, method="BFGS")  
  
alpha_ml <- exp(fit.ml$par)  
gamma_ml <- alpha_ml / mean(x)  
  
logL_ml <- -fit.ml$value
```

Den git at $\hat{\gamma}_{ML} = 0.05751589$ og $\hat{\alpha}_{ML} = 1.388346$, og da at $l(\hat{\alpha}_{ML}, \hat{\gamma}_{ML}) = -26488.28$. Log-likelihood-verdien for ML-estimatene er helt rimelig fordi den er høyere enn verdien fra moment-estimatene i (b), slik man alltid forventer når man maksimerer funksjonen.

(e)

Implementasjon:

```
B <- 1000 # Antall bootstrap-simuleringer  
n <- length(x)  
  
alpha_boot <- numeric(B)  
gamma_boot <- numeric(B)  
  
for (i in 1:B) {  
  x_b <- sample(x, size = n, replace = TRUE)  
  
  fit_b <- optim(log(alpha), negloglikgamma, x = x_b, method = "BFGS")  
  
  alpha_boot[i] <- exp(fit_b$par)  
  gamma_boot[i] <- alpha_boot[i] / mean(x_b)  
}
```

Da får vi følgende anslag for standardfeilen (SE) til maksimum likelihood-estimatene:

$$SE(\hat{\alpha}_{ML}) \approx 0.0297$$

$$SE(\hat{\gamma}_{ML}) \approx 0.0019$$

Og vi får vi følgende 95 % konfidensintervaller:

$$95 \% \text{ KI for } \alpha : [1.335, 1.450]$$

$$95 \% \text{ KI for } \gamma : [0.0542, 0.0614]$$

(f)

Implementasjon:

```
mu_boot <- alpha_boot / gamma_boot

ci_mu_95 <- quantile(mu_boot, c(0.025, 0.975))
ci_mu_99 <- quantile(mu_boot, c(0.005, 0.995))
```

Da får vi følgende konfidensintervaller for forventningsverdien μ :

```
95 % KI for  $\mu$  : [23.43, 24.81]
99 % KI for  $\mu$  : [23.29, 24.96]
```

Vi tester hypotesene $H_0 : \mu = 25$ mot $H_a : \mu \neq 25$.

Siden $\mu = 25$ ligger utenfor det brede 99 % konfidensintervallet, forkaster vi nullhypotesen på signifikansnivå $\alpha = 0.01$. Ettersom 99 %-intervallet innerholder 95 %-intervallet, forkastes nullhypotesen i tillegg på signifikansnivå $\alpha = 0.05$.

Da får vi følgende konklusjon for P-verdien:

P-verdi < 0.01

Oppgave 2

a)

Siden den sanne variansen σ^2 er ukjent og vi antar at målingene er uavhengige og normalfordelte, benytter vi en t-fordeling med $n - 1 = 14$ frihetsgrader.

Implementasjon:

```
x <- c(525, 587, ..., 562)
n <- length(x)

x_bar <- mean(x)
s <- sd(x)
t_val <- qt(0.975, df = n - 1)

nedre <- x_bar - t_val * s / sqrt(n)
ovre <- x_bar + t_val * s / sqrt(n)
```

Datasettet gir følgende konfidensintervaller for forventet antocyaninnhold, μ :

$$\begin{aligned} 95 \% \text{ KI for } \mu &= \bar{x} \pm t_{0.025, 14} \frac{s}{\sqrt{n}} \\ &= [543.85, 575.48] \end{aligned}$$

b)

Implementasjon:

```
B <- 10000
n <- 15
mu_sann <- 558
sigma_sann <- 30

sim_data <- matrix(
  rnorm(B * n, mean = mu_sann, sd = sigma_sann),
  nrow = B,
  ncol = n
)

x_bar <- rowMeans(sim_data)
s <- apply(sim_data, 1, sd)
t_val <- qt(0.975, df = n - 1)
feilmargin <- t_val * s / sqrt(n)

nedre_grense <- x_bar - feilmargin
ovre_grense <- x_bar + feilmargin

dekker_mu <- (nedre_grense <= mu_sann) & (ovre_grense >= mu_sann)

andel <- mean(dekker_mu)
```

Andelen var 0.9517, Noe som er en godt tilnærming på 95 %. Dette resultatet illustrerer selve definisjonen av et konfidensintervall. At vert konstruert interval har en 95% sansylighet for å inneholde μ .

c)

Implementasjon:

```
feilmargin_stor <- 1.96 * s / sqrt(n)

nedre_grense_stor <- x_bar - feilmargin_stor
ovre_grense_stor <- x_bar + feilmargin_stor

dekker_mu_stor <- (nedre_grense_stor <= mu_sann) & (ovre_grense_stor >= mu_sann)

andel_stor <- mean(dekker_mu_stor)
```

Når vi bruker det tilnærmede intervallet, viser simuleringen at andelen synker til 0.9325. Dette stemmer med at denne tilnærmingen antar at vi har mer informasjon om standardavviket enn vi faktisk har, og dermed lager et for smalt intervall.

d)

For å konstruere et konfidensintervall for standardavviket σ i en normalfordeling, benytter vi kji-kvadrat-fordelingen. Vi vet at størrelsen $\frac{(n-1)S^2}{\sigma^2}$ er χ^2 -fordelt med $n - 1$ frihetsgrader. Ved å snu på dette uttrykket, får vi følgende formel for et 95 % konfidensintervall for σ :

$$\left[\sqrt{\frac{(n-1)s^2}{\chi_{0.975,14}^2}}, \sqrt{\frac{(n-1)s^2}{\chi_{0.025,14}^2}} \right]$$

```
chi_nedre <- qchisq(0.025, df = n - 1)
chi_ovre  <- qchisq(0.975, df = n - 1)

nedre_grense_sigma <- sqrt((n - 1) * s^2 / chi_ovre)
ovre_grense_sigma  <- sqrt((n - 1) * s^2 / chi_nedre)

dekker_sigma <- (nedre_grense_sigma <= sigma_sann) & (ovre_grense_sigma >= sigma_sann)
andel_sigma  <- mean(dekker_sigma)
```

Når vi kjører denne simuleringen finner vi at andelen er 0.9489 som er tilnærmet 95 %, akkurat som forventet.

e)

Implementasjon:

```
sim_data <- mu_sann + sigma_sann * matrix(
  rt(B * n, df=7),
  nrow = B,
  ncol = n
)
```

Når vi kjører simuleringen er andelen 0.9511, som fremdeles ligger svært nær 95 %.

Dette resultatet viser at metoden for å lage konfidensintervall for forventningsverdien er svært robust mot avvik i antakelsen om normalfordeling.

f)

Implementasjon:

```
sigma_tilde <- sigma_sann * sqrt(7 / (7 - 2))  
dekker_sigma_tilde <- (nedre_grense_sigma <= sigma_tilde) & (ovre_grense_sigma >= sigma_tilde)  
andel_sigma_tilde <- mean(dekker_sigma_tilde)
```